LABORATUVAR 7 · GENEL SÜRÜM · Yektamak Modüler Konveyörlü Dolum Hattı

AI Safety Challenge

Ad Soyad: Şevval Öcal | Grup / Şube: İÖ 4. Sınıf | Tarih: 06.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?**

   Cevap: Davranış: YZ'nin OK verdiği durumlarda, mekanik/lazer emniyet bariyeri veya ağırlık/basınç sensörü bağımsız bir ikinci doğrulama (secondary check) yapar. Uyuşmazlık durumunda fiziksel ayırma pistonu devreye girer (fallback) ve vardiya operatörüne onay bildirimi (human override) düşer.

2. **Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?**

   Cevap: Fark Etme: Görüntü işleme katmanında framerate düşüşü, donma veya kontrast/gürültü sapmaları veri izleme (monitoring) protokolü ile anında fark edilir. İşlem: Şüpheli akış algılandığında YZ karar mekanizması devre dışı bırakılır, hat güvenli yavaş moda geçer ve güvenli duruş (fail-safe) tetiklenir.

3. **Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?**

   Cevap: Eşik Değeri: Güven eşiği min %92 (confidence threshold) belirlenir. Eşik Altında: YZ tahmini reddedilir, robotik dolum kafası hat üzerinde durdurulmadan şüpheli şişe ıskarta mekanizmasına yönlendirilir (fallback) ve SCADA ekranında insana yönlendirilir (insana sor).

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci fiziksel sensör kontrolü ve şüpheli ürünü ayırma pistonuna yönlendirme (Fallback + Human Override).
Girdi manipüle edildi	Görüntü doğrulama hatasında YZ yetkisini alıp emniyet moduna geçiş yapma (Monitoring + Fail-Safe).
Confidence düştü	%92 eşik altı tahminlerde kararı reddedip operatör onayına ve güvenli ret kanalına aktarma (Confidence Threshold + Fallback).

Bu föyün çıktısı AI Fail-Safe Decision → Evidence Pack EP 03 + EP 15 başlığına oturur.